

AI发展趋势追踪及AI应用侧竞争分析



【关键发现】

1. 产业都有转折点，从“技术奇观与烧钱”转向“应用普及与盈利”，AI浪潮处在上下半场转折点，海内外大厂正全力探索商业化落地模式

- 海内外大厂创始人/核心高层均在探索如何利用AI创造商业价值，AI能力侧逐渐聚焦图像/视频生成
- AI 仍处在长期发展过程，Scaling Law尚未撞墙但技术进步放缓，中美有不同瓶颈待突破
- OpenAI是AI上下半场转换的关键节点，其26年财务承压和商业化决策标志着行业向下半场转变

*最新消息追踪（2026年1月17日）：OpenAI 公开宣布在免费和GO版本中测试广告

2. 大厂从基础模型厮杀转向AI应用扩张，图文视频生成类及其相关AI应用赛道逐渐被大厂蚕食，依托传统行业成熟商业模式的AI创新应用有更大概率突破大厂包围

- AI在B/C端出现使用分化，B端业务聚焦AI编程且强绑定模型能力，C端向强化版搜索发展

*姚顺雨（腾讯首席AI科学家）最新观点追踪（2026年1月）：AI在B/C端出现使用分化，B端业务聚焦AI编程且强绑定模型能力，C端向强化版搜索发展

- C端AI应用竞争大厂优势明显且持续侵蚀榜单，小厂/创业公司在特定场景依托专业壁垒生存，AI作为拓展能力和助力破圈的工具
- AI音乐学园依靠社群起家，AI仅作为能力拓展及破圈的手段，赚钱逻辑依然是教育服务付费
- TalkAI聚焦外语口语教育的垂类场景，通过AI能力降低口语训练价格快速占领市场，仅进行场景创新和体验提升的小投入
- B端对模型能力感知强，高收入行业（当前聚焦码农）更愿意为强大模型能力支付高价

3. 雷鸟自身具备硬件制造/大屏交互/流量变现等能力优势，持续筛选商业模式成熟的toC行业，在转折期更重要的是提供孵化AI的场景并避免筛选AI的具体技术路线

- 能持续生存的小厂/创业公司锚定已被验证过商业模式的toC行业（教育大类）或稳定需求且高收益的toB业务（AI编程）

- 小厂/创业公司深耕成熟赚钱赛道，主要**依靠AI能力降本+破圈**
- 在大众消费者对模型能力强弱感知不明显情况下，**选择AI相关但不被AI改变的行业**更适合当前充满未知且充分竞争的市场环境


1. AI浪潮正处在上下半场转折点，从“技术奇观与烧钱”转向“应用普及与盈利”，海内外大厂正全力探索商业化落地模式

1.1 过去250年五次技术/产业革命均经历了**导入期金融资本助推直至泡沫产生，转折步入展开期金融+生产协同落地至行业成熟**

- 电力网络、石油基建等重资产领域遵循：初期依赖金融资本的狂热投入完成基础设施铺设，泡沫破裂后生产资本接盘，最终实现技术与经济的深度融合
- 本轮AI浪潮同样依赖金融资本的狂热投入助推基础设施建设，**与前几次技术革命有强相似性**

技术革命	时间跨度	核心技术	导入期：爆发→狂热→崩溃	展开期：协同→成熟	基础设施
蒸汽机	1771-1842年	纺织机械、蒸汽机、煤炭	爆发：蒸汽机技术突破，金融资本涌入纺织业 狂热：运河、矿山投资热 崩溃：1825年英国金融恐慌	协同：蒸汽机普及到采矿、交通，生产资本主导效率提升 成熟：纺织业成为支柱，英国确立工业霸权	矿山、运河开发
铁路	1829-1897年	铁路、蒸汽机、钢铁	爆发：铁路技术突破，金融资本疯狂投入铁路建设 狂热：全球铁路投机热潮 崩溃：1847年铁路股灾	协同：铁路网成型，带动煤炭、钢铁产业协同发展 成熟：铁路成全球物流核心，重塑经济地理格局	铁路建设
电力	1875-1950年	电力、化工	爆发：电力技术突破，金融资本涌入电厂、电网建设 狂热：电气设备、工业股暴涨 崩溃：1907年金融危机	协同：电网普及，重工业体系落地，资本主导规模化生产 成熟：电力成为社会基础能源，重工业支撑现代工业	电网、钢厂建设
石油/汽车					

	1908–1974年	汽车、石油、内燃机、流水线	爆发：汽车技术突破，金融资本涌入汽车、石油产业 狂热：汽车股、石油投机 崩溃：1929 年大萧条	协同：石油基建完善，汽车普及，流水线生产重构制造业 成熟：汽车成大众消费品，石油能源体系主导全球经济	油田开发、公路建设
信息技术/通信	1971–2020年	计算机、互联网、半导体	爆发：半导体技术突破，金融资本涌入硅谷 狂热到崩溃：2000 年互联网泡沫、2008 年金融危机	协同：互联网普及，云计算、大数据落地，企业数字化转型 成熟：数字经济成为核心	数据中心、光纤网络



基于《技术革命与金融资本》整理的AI浪潮

1.2 海内外大厂创始人/核心高层均在探索如何利用AI创造商业价值，招聘方向从“研究型科学家”逐渐转向“商业化落地专家”，应用能力逐渐收敛至图像/视频生成

1.2.1 海内外大厂24年起尝试商业化，25年进一步发力围绕Agent继续探索商业化落地可能性

- 2023年，海内外大厂围绕大模型激烈竞争：焦点是谁的模型参数大、评分高、推理能力强

- 2024年，各家围绕“入口”尝试商业化但未成功：焦点是谁能把模型塞进现有的超级App（Office, 微信, Instagram, 钉钉），初步尝试“Copilot”模式，人主导+AI 辅助
- 2025年，围绕Agent加速商业化落地但效果仍不显著
 - OpenAI Operator尝试操作浏览器，完成订票、购买等常规任务
 - 字节豆包正尝试围绕办公场景成为随身硬件助理；阿里和Amazon试图企业内部自动流转审批和代码修复

1.2.2 海内外大厂开始发力宣传“AI创造商业价值”的可能性，且应用能力收敛至图像 / 视频生成

- 各大厂从原本专注讲述模型架构技术实现，到如今向消费者和企业宣传**各类“AI创造商业价值”的可能性**
- **图像 / 视频**能力成为发布会核心演示内容，多模态理解与创作一体化越来越多被大厂提及
- 所有大厂都在重点讲述**企业级智能体**，AI逐渐变为“执行助手”，企业级落地成为大厂竞争的核心战场

公司	高层23/24年公开发声	时间	高层最新发声	时间	发布会内容概述
OpenAI	"我们希望能在各个方面都取得突破，但目前我们特别关注模型的推理能力..." —— CEO Sam Altman	2024.11	“AI不再是我们测试的对象，而是我们共同生活和创造的伙伴。这是我们这一代的 Apple II 时刻...” ——CEO Sam Altman	2025.10	• 推出GPT-5 Pro • 开放Sora 2 API 预览版 • 发布企业级智能体开发套件 AgentKit
谷歌	“我们的重点是模型的基础效率，确保我们能通过架构创新，以更小的碳足迹提供最先进的性能...” —— CEO Sundar Pichai	2023.05	“AI竞赛已经从‘刷榜（Benchmarks）’转向了‘赚钱（Money-making applications）...’” ——CEO Sundar Pichai	2025.11	• 发布 Gemini 3 Pro 模型 • 推出 Veo 3.1 视频模型 • 发布 Nano Banana Pro 图像模型 • 升级 AI 助手为 Project Astra
meta	"很多人觉得 AI 应用是‘上层建筑’，但对我们来说，底层架构才是‘地基’。比如 Threads 的 AI 内	2023.02	“最好的技术应该‘隐形化’。当智能眼镜取代手机，AI 范式就完成了从屏幕到现实的跃迁...”	2025.09	• 升级 Emu 3.5 图像模型 • 推出 Movie Gen 系列模型

	容推荐，依赖于我们的‘分布式推理集群’ ..." —— CEO Mark Zuckerberg		——CEO Mark Zuckerberg		发布三款智能眼镜新品
亚马逊	“推理成本最终将成为 AI 普及的最大障碍，这就是为什么我们的架构重点在于芯片的长期效率...” ——CEO Andy Jassy	2023.11	“大模型的‘技术奇观’阶段已经过去，我们正处于智能体（Agent）改变业务逻辑的拐点...” ——AWS CEO Matt Garman	2025.12	- 推出Nova 2 系列模型，含多模态Omni版本 主推企业级Agent，升级 AgentCore 工具套件
xAI	“AI 领域的真正竞争在于谁能实现将电能转化为智能 Token 的最高效率...” ——CEO Elon Musk	2023.11	“Grok 4.1 标志着我们不再仅仅追求知识量，而是追求在复杂逻辑下的‘意识自主性’ ...” ——CEO Elon Musk	2025.11	推出具备深度推理能力的 Grok 4.1 Thinking - 发布 Aurora 图像生成模型 - Grok Imagine 视频生成功能
字节	"底层模型的研发需要极大的耐心和危机感，不能因为短期没有看到应用爆发就放松投入..." ——CEO 梁汝波	2023.4	“大模型性能的‘边际效应’正在递减，应用层范式的爆发才是未来的主旋律。模型只是发动机，Agent 才是车...” ——火山引擎总裁 钟灿峰	2025.12	- 升级豆包大模型 1.8 升级 Seedream 4.0 图像模型 - 发布 Seedance 1.5 Pro 视频模型 推出AgentKit企业级智能体开发平台
阿里	"大模型的长跑才刚刚开始，底层架构的稳健性和可扩展性将决定谁能笑到最后..." ——CEO 吴泳铭	2023.11	“AGI（通用人工智能）并非终点，而是起点。AI正从智能涌现迈向‘自主行动’的新范式...” ——CEO 吴泳铭	2025.09	- 发布 Qwen3-Max 旗舰模型 - 预览 Wan2.5 系列多模态模型 - 推出羚羊 AgentOne 平台

腾讯	"AI 是百年不遇的工业革命，我们不急于早早做完应用，而是要把底层的架构和模型打磨扎实..." —— CEO 马化腾	2023.05	“AI已成为腾讯的新基因。我们现在的任务是把大模型打磨成‘好用的AI’，在千行百业扎根...” ——高级执行副总裁汤道生	2025.09	- 发布 Hunyuan 3D 3.0 - 发布智能体平台 3.0 - 展示AI+消费场景落地成果
----	---	---------	---	---------	---

1.2.3 海内外头部大厂招聘方向从“研究型科学家”逐渐转向“商业化落地专家”

- 初期招聘倾向：偏好能通过堆砌算力和数据规模创造奇迹的研究型科学家，数学等基础学科方向更多
- 中期招聘倾向：AI研究员开始向机器人学、多模态感知和端到端控制领域迁移

特斯拉的人才流失到Sunday Robotics，以及Meta重金挖掘感知团队（Perception Team），都是这一趋势的体现


- 25年招聘倾向：从“模型训练工程师”转向“智能体编排专家”
 - 2025年是“Agentic Workflows”的元年，人才需负责构建让多个专用AI模型相互协作、调用外部工具、并进行自我修正的复杂系统

公司	2023 年	2024 年	2025 年
OpenAI	11月：Altman 离职 / 重返 + 董事会重组	6月：收购远程协作AI初创公司 Multi	9月：11亿美元收购Statsig（创始人任 CTO） 10月：收购理财APP Roi 12月：收购AI工具平台Neptune
Google	4月：合并 Google Brain 与 DeepMind 为 “Google DeepMind”，Demis Hassabis 任 CEO、Jeff Dean 任首席科学家	8月：27亿美元与Character.AI 战略合作	4月：Gemini负责人Sissie Hsiao（1980年，历任微软产品经理、谷歌AI语音助手业务）辞职，Josh Woodward（1983年，历任牛津研究员，谷歌教育/文档工具业务）接任
AWS	4月：Swami Sivasubramanian为ML部门全球副总裁，负责Bedrock、SageMaker等生成AI核心服务研发与商业化	3月：AI业务副总裁Baskar Sridharan离职 6月：生成式AI全球副总裁 Vasi Philomin离职，从 Adapte挖多位联创加入AI部门	12月：首席科学家Rohit Prasad（1975年，Alexa 首席科学家）离职，Peter DeSantis（1975 年，构建AWS计算、存储、网络核心产品线）牵头新AI部门，Pieter Abbeel（1977年，“AI 创

			业教父”，公司被亚马逊收购）任AGI团队负责人
Tesla	8月：AI芯片团队并入Ashok Elluswamy的Autopilot部门	10月：Dojo 团队核心成员Eric Quinnell 离职（主导Dojo Fabric 研发）	8月：Dojo 团队解散，负责人Peter Bannon离职 擎天柱主管Milan Kovac、软工副总裁David Lau离职
Meta	—	2月：前OpenAI资深研究员Alec Radford（GPT-3/GPT-4）加入 Meta，任 FAIR 实验室生成式 AI 首席研究员	6月：143 亿美元入股 Scale AI（49% 股份），Alexandr Wang 任首席AI官，成立 Superintelligence Labs 10月：裁撤 AI 部门 600 人 11月：首席AI科学家Yann LeCun宣布离职 12月：收购 Manus，创始人肖弘任副总裁
阿里巴巴	6月：张勇卸任集团 CEO，吴永明接任；蔡崇信任董事长	7月：通义千问技术负责人周畅离职（10月加入字节）	4月：通义实验室薄列峰（应用视觉）、鄢志杰（语音）离职 12月：云计算CTO / 通义实验室负责人周靖人成阿里合伙人
字节跳动	年中：从AI Lab/AML/搜索团队抽调人手组建Seed（豆包大模型）团队，向梁汝波汇报	4月：AI Lab整体并入Seed团队，李航转任顾问 10月：挖来阿里周畅及其团队加入Seed	2月：前 Google DeepMind 副总裁吴永辉加入任 Seed 基础研究负责人 7月：Seed视觉多模态负责人杨建朝“暂休”，周畅接棒 10月：吴永辉成Seed负责人（朱文佳汇报线调整至吴永辉）
腾讯	上半年：TEG 大数据部门胜出，组建“混元大模型团队”，蒋杰（TEG 副总裁）负责	3月：腾讯混元大模型团队负责人蒋杰晋升TEG 高级副总裁，负责AI技术商业化落地	9月：前OpenAI研究员姚顺雨加入任首席AI科学家 12月：重组AI部门，成立“AI 基础设施”团队，姚顺雨牵头 12月底：腾讯AI Lab副主任、科学家俞栋离职（学术+产品）

1.3 OpenAI是AI上下半场转换的关键节点，其26年的巨大财务承压和商业化决策标志着行业向下半场转变

*最新消息追踪（2026年1月17日）：**OpenAI 公开宣布在免费和GO版本中测试广告**



对比项	甲骨文	微软	AWS	CoreWeave	AMD	NVIDIA	博通
合作方式	甲骨文建设，OpenAI租赁	OpenAI 向微软购买云服务	AWS建设，OpenAI租赁	coreweave建设，OpenAI租赁	芯片采购(数百亿美元)+10% 股权期权	每 1 吉瓦直接投资 100 亿美元 现金，共建10 吉瓦	共同开发10 吉瓦定制 AI 加速器，OpenAI 支付设计/部署费
资金流向					OpenAI 向 AMD 支付芯片款	英伟达向 OpenAI 投资，后者再采购 NVIDIA 芯片 形成"投资 - 采购 - 部署" 闭环	

1.3.1 OpenAI 26年面临巨大增长压力（3倍营收），千亿级CAPEX需每年新增\$650亿收入以达成盈亏平衡，预计2030年仍无法实现

- 26年依现有算力租赁合同，固定花费预计：981亿美元
- 27年依现有算力租赁合同，固定花费预计：1081亿美元

单位：\$bn						
年份	2025	2026	2027	2028	2029	2030
自由现金流	-7.03	-60.69	-75.54	-68.94	-58.21	-13.42
新的股权融资	-	20	72	67	53	5
收入	12.50	35.00	68.00	106.89	153.79	213.59
云计算成本	25.69	87.31	127.90	158.50	193.00	206.75

source: 汇丰银行的投资者建议报告

- OpenAI业务增长需求属于高毛利路径（云服务/软件），边际贡献率为70%（最乐观估计），需每年新增\$643亿收入

$$R_{needed} = \frac{(CAPEX \times \text{折旧率}) + \text{年化运维成本 (OPEX)}}{\text{业务边际贡献率}}$$

- **资产折旧率：**服务器及GPU生命周期短，AI领域由于算力迭代快，通常采用**5~6年**折旧

亚马逊财报：

- 于 2024 年 1 月 1 日起，将服务器的使用寿命从5年延长至6年
- 自 2025 年 1 月 1 日起，将部分服务器及网络设备的使用寿命从6年调整为5年


谷歌财报：

- 服务器、网络设备等硬件采用 “直线折旧法”，即资产总成本在预计使用寿命内平均分摊，折旧费用固定
- 服务器和网络设备折旧时间：6年

- **运维成本 (OPEX)：**包括巨大的电力消耗（AI 数据中心电费占比极高）、散热、固保、网络带宽以及高昂的人才薪酬。通常设定为CAPEX的**20%~30%**
- **边际贡献率：**对于 SaaS 或云服务，**边际利润较高（约60%~80%）**；对于电商（阿里、字节）或硬件（特斯拉），综合利润率较低（约0%~30%）
- **根据已有算力租赁合同及外部报告数据，OpenAI年投入约\$1000亿AI CAPEX：**
 - **年化支出 (Cost Side)：**
 - 折旧 (5年平摊)：\$200 亿
 - 运维与电力 (25% CAPEX)：\$250 亿
 - **合计每年新增硬支出：约 \$450 亿**

1.3.2 OpenAI面临Google强力竞争，且AGI的宏大叙事带来发布会评价下滑与舆论恶化

- OpenAI：定位从“**AGI的早期版本**”逐步升级为“**博士级+AGI关键一步**”，押注态势持续清晰；舆论从“狂热正面”逐步下滑至“极度恶化”，GPT-5发布会成为主要拐点
- Google：定位**始终淡化AGI，聚焦实用能力提升**；舆论从“灾难性负面”逐步回升至“**正向反馈超预期**”



1.4 AI 仍处在长期发展过程，Scaling Law 尚未撞墙但技术进步放缓，中美有不同瓶颈待突破

- 美国的瓶颈在电力/能源（from Google/Tesla 博客与访谈），中国的瓶颈是芯片（from 腾讯/字节专家访谈）
- Google Deepmind CEO 否认“Scaling Law 撞墙”但预估实现 AGI 时间为 5 到 10 年，AI 的发展问题最终都会归结为能源问题

- 我认为规模定律总体上仍然进展得非常好。只要投入更多算力、更多数据，把模型做得更大，我们确实能看到能力的持续提升。当然，这种提升的速度可能不像两三年前那么快了
- 要达到 AGI，不能只靠 Scaling Law，还需要 1-2 个像 Transformer 那样的重大范式突破
- 实现 AGI 的过程中限制很多，芯片永远不够，算力需求远远超过供应，而算力最终都归结为能源问题。未来，能源几乎会成为“智能的货币”

——Google Deepmind CEO Demis Hassabis，2026 年 1 月 CNBC 访谈节目《科技下载》

- 腾讯同样认为 AI 发展是漫长过程且目前处于早期阶段，若 C 端需求继续扩张 agent 广泛普及，则国内算力尤其是推理算力将严重不足

- 国内 AI 放量的核心影响因素是算力，尤其是推理算力不够。若 agent 广泛普及，所需算力将大幅增加，国内算力可能无法满足全面铺量需求
- AI 发展是一个长期过程，目前仍处于早期阶段，scaling law 远未到头，后续在预训练、强化学习优化模型等方面还有很大进步空间

——2026 年 1 月腾讯 AI 内部交流会

1.4.1 AI 受限于 Scaling Law 且拥有更长的 S 型曲线，有别于互联网“先到先得，强者恒强”，先发未必先至

- 互联网的 S 曲线：“成长期更陡、成熟期更快”，互联网是“工具革命”，核心价值是“降低信息传递成本”，属于“增量创新”（原有场景效率提升，如线下购物→电商）。技术逻辑是“标准化协议 + 规模化覆盖”，一旦基础设施（网络、终端）到位，应用可快速复制
- AI 的 S 曲线：“启动期更长、成长期斜率更缓、成熟期门槛更高”，AI是“能力革命”，核心价值是“替代人类认知劳动”，属于“颠覆式创新”（创造新场景，如 AI 辅助药物研发、智能驾驶）。技术逻辑是“个性化适配 + 复杂系统协同”，即使模型技术成熟，仍需适配不同行业的流程、数据、合规要求，无法简单复制

核心维度	AI (Scaling Law)	互联网 (梅特卡夫定律)
核心驱动	参数 / 算力 / 高质量数据的协同扩张，核心遵循幂律关系 (性能≈投入 ^a, a 为幂律指数)	用户数量扩张，核心是“用户间连接数”的 n ² 级增长
边际收益变化	先递增 (a 值主导协同效应，投入放大性能)，后递减 (幂律特性导致投入指数级增长，性能逼近天花板)	长期递增 (用户突破临界点后，连接价值正反馈强化)
成本特性	边际成本递增 (算力 / 数据标注 / 模型维护成本指数级上升)	边际成本递减 (新增用户的服务器 / 运营成本趋近于零)

	互联网革命 (1960s-2020s)	AI 革命 (1950s - 至今)
S曲线三阶段特征		
启动期 (萌芽→技术突破)	时长：30 年 (1969 ARPAnet→1995 Netscape 浏览器商业化) 关键突破：TCP/IP 协议、WWW、浏览器	时长：60 年 (1956 达特茅斯会议→2012 AlexNet 深度学习突破→2017 Transformer 架构) 关键突破：深度学习、Transformer、大模型 (GPT3)
成长期 (爆发→规模化)	斜率：陡峭 (用户渗透快) 时长：10~15年 (1995-2010 桌面互联网；2010-2020 移动互联网) 标志：全球网民从 1%→50% 仅用20年 (1995-2015)	斜率：较平缓 (分场景渗透) 时长：已持续13+年 (2012 - 至今)，现在未达峰值 标志：生成式AI用户从 0→10 亿用 3 年 (2020-2023)，但 B 端渗透率不足 20%
成熟期 (饱和→稳态)	时长：10 年 (2020 后流量见顶，进入存量竞争)	尚未进入成熟期 (预计2035后) 特征：技术仍在迭代 (模型效率/多模态)，B 端场景仍在验证，商业闭环未

	特征：用户渗透率超 60%，商业模式固化（广告、电商、订阅）	完全形成
核心目标	信息连接：人-人、人-信息、人-服务	智能决策：替代 / 辅助人类完成认知、分析、创造类任务
AI革命S曲线更长的底层原因		
整体技术复杂度	✓ 短链路 基础设施（通信协议、服务器）→平台（操作系统、浏览器）→应用（网站、APP） 核心门槛：通信技术、产品体验	✗ 长链路 底层硬件（GPU/ASIC）→框架（TensorFlow/PyTorch）→模型（大模型 / 垂类模型）→应用（C 端工具 / B 端系统）→场景适配（行业定制） 核心门槛：算法创新、数据治理、工程化落地、行业知识
用户渗透速度	✓ 用户渗透快 （C 端）移动互联网用户从1亿→30亿用8年（2010-2018），年复合增长率50%+	✓ 用户渗透快 生成式 AI 用户从 1 亿→10 亿用 3 年（2020-2023），且用户增长快速得益于互联网模式的成熟
商业落地周期	✓ 商业落地快 从技术突破到盈利平均3-5年 Eg. 如 Facebook 2004 成立，2009 盈利	✗ 商业落地探索中，盈亏平衡难度大 从技术突破到盈利超8-10年 Eg. OpenAI 2015成立，2025年尚未盈亏平衡且预计持续亏损至2030年

2. 大厂从基础模型厮杀转向AI应用扩张，图文视频生成类及其相关AI应用赛道逐渐被大厂蚕食，依托传统行业成熟商业模式的AI创新应用有更大概率突破大厂包围

姚顺雨（腾讯首席AI科学家）观点追踪：AI在B/C端出现使用分化，B端业务聚焦AI编程且强绑定模型能力，C端向强化版搜索发展

- AI在toC、toB当前出现明显的分化，C端场景模型能力要求低，B端则是越强越有付费意愿

toC日常场景不需要那么强大的模型能力，强化的智能搜索满足绝大多数人的使用

toB模型能力越强人们越愿意付费（美国市场尤为明显），净值越高的人越要用最强的模型（200刀每月也接受）
- 腾讯是一个toC属性更强的公司，所以AI在toB端他计划先把腾讯自身的业务服务好
- 下一代大模型进化方向为自主学习，核心是数据与场景

自主学习是共识，瓶颈已经不是方法论了，而是**数据或任务**


后面模型或者说AI能力的提升更多是**渐变而不是突变**

OpenAi 是概率更大的诞生新范式的公司，但因为它商业化的各种变化，创新的基因已经被削弱

2.1 C端AI应用竞争大厂优势明显且持续侵蚀榜单，小厂/创业公司在特定场景依托专业壁垒生存，AI作为拓展能力和助力破圈的工具

2.1.1 大厂持续侵蚀top50应用榜单且上榜门槛持续升级，应用覆盖文字、图像、视频生成与编辑

- 大厂/头部大模型公司所开发应用占比持续提升（top20榜更明显），主力仍是通用模型类应用，并在虚拟角色、搜索、视频编辑/创作赛道竞争优势明显（占据绝对头部，小厂在后方交替厮杀抢榜）
- 通用模型、搜索引擎、toC视频创作/编辑全部被大厂统治，无竞争机会
- 导航类、效率提升类（PPT、思维导图、研发、文档等一系列）、写作类、图像生成/编辑类应用门槛低（大模型泛化能力最先攻克领域），随通用模型能力泛化被直接吞并或挤压，不具进入意义



		具体应用类型		字节	阿里	腾讯	百度
C端	通用入口	移动		豆包/Cici	千问/蚂蚁灵光	元宝	文小言
		PC		豆包浏览器	夸克浏览器	QQ浏览器	百度搜索
	垂类应用	消费软件	AI陪伴	猫箱	/	/	/
			AI相机	星绘	妙鸭	/	/
			AI教育	豆包爱学 / Gauth	千问哲学	/	/
			AI健康	小荷AI医生	蚂蚁阿福	/	

							文心健康管家
			AI音乐	汽水音乐	/	QQ音乐	/
			AI小说	番茄小说	/	作家/漫画助手	百度作家助手
		生产力软件	AI地图	/	高德地图	腾讯地图	百度地图
			AI办公	扣子空间/飞书	钉钉	腾讯会议	如流/百度文库
			AI理财	/	支付宝-蚂小财	理财通	/
			AI视频	剪映/即梦	通义万相	混元AI视频	百度AI成片
			AI图片	即梦AI	通义万相	混元DIT	文心一格
	消费硬件	AI手机		豆包AI手机	/	/	/
		AI眼镜		/	夸克AI眼镜	/	小度AI眼镜
		AI耳机		Ola Friend	/	/	/
		AI音箱		/	天猫精灵	/	小度音箱
B端	云服务	GPU租赁		火山引擎	阿里云	腾讯云	百度智慧云
		MaaS服务		火山引擎	阿里云百炼	腾讯云TI	千帆大模型
		解决方案	AI客服平台	扣子 (Cozo)	百炼Smart	元器	文心智能体
			AI数字人	/	通义晓尘	/	客悦One
			AI代码	火山引擎数字人 TRAE	通义星尘/通义灵码	腾讯云 Codebuddy	文心快码 Comate
	AI芯片	自研AI芯片		(未命名)	平头哥	紫霄	昆仑芯

2.1.2 教育学习/音乐（专业沉淀属性强）及编程/设计（工作效率提升）类应用尚有稳定生存空间

- 规模大但专业性强：**教育学习类应用，通过**专业能力和经验沉淀**的创业/传统企业孵化的AI应用持续占据榜单前列，且即使面对大厂飞轮的冲击仍保持稳定增量；尤其是**教育学习类**，专业护城河很深（大厂只有字节挤入成功，但其2018年已深耕教育板块，也是专业沉淀+大模型能力）

- **规模小导致大厂进入代价高：**音乐创作、设计工具、虚拟陪伴（二次元），这三类涉及**偏小众使用者**（音乐爱好者、设计师、二次元）赛道，有垂类流量且大厂受限决策机制较难进入，完全由有专业积累和时间沉淀的小厂开发者垄断（本身为传统应用此类型玩家，AI功能仅是能力提升作用）

启发：利用垂类流量和用户特征运营社群并建立良好绑定关系，避免同大厂/大模型公司在模型能力上比拼，而是深耕垂类场景，做精准且小而美的应用

应用类型	代表应用	应用背景	竞争表现
音乐创作	AI 音乐学园	爱玩吉他社群孵化	16个月持续赛道第一且持续增长，Muse AI等新玩家介入后依旧未受影响
设计工具	Canva 可画	Melanie Perkins夫妻创业	12个月持续赛道第一且持续增长，垄断设计工具赛道
教育学习	Talk AI	CEO-Mark，深圳创业公司	16个月保持赛道top2，仅落后豆包爱学（字节孵化）
	海豚AI学	猿辅导	12个月持续上榜且仅落后于字节系教育类应用
	新概念AI版	新概念英语	6个月持续上榜且排名稳步提升中



国内top50 AI应用榜单公司类型占比&AI 各赛道应用分布



2.2 AI音乐学园依靠社群起家，AI仅作为能力拓展及破圈的手段，赚钱逻辑依然是教育服务付费

- 基本垄断AI 音乐创作这一偏小众、专业爱好赛道，MAU从24年数据监测以来稳健增长并于25年迎来规模爆发
- 创始人从运营“爱玩吉他”社区起家，早期服务单一乐器品类（吉他、尤克里里）的爱好者和教育者（聚焦青年人），逐步通过融资和AI技术扩展乐器品类和用户年龄范围
- 2021年起不再有公开融资讯息，2025年付费用户达100万+，已构建稳定赚钱模式

启发：由特定爱好发展为社群并成为意见领袖，再运营应用逐渐扩圈、用AI拓展品类逐渐扩大服务范围，进而成为整个小赛道的主流玩家（canva、Lovekey等应用同理）



时间	融资轮次	融资数额	投资机构
2015年初	天使轮（爱玩吉他）	400 万元	伙伴创投领投

2019年2月	Pre-A轮融资	数千万	基因资本、港粤资本、京北投资等联合投资
2021年2月	A轮融资	数千万	网易有道（网易有道入股，成为公司第五大股东，持股比例为5.69%）
2021年7月	A轮+融资	数千万	网易云音乐旗下基金

1. 融资情况

<https://36kr.com/p/1721072091137>

<https://xueqiu.com/8707480199/172203834>

2. 用户增长情况：

2017 年：**AI 音乐学院 APP 上线三个月即实现盈利**，成为国内少数早期实现盈利的在线音乐教育平台

2019 年：付费用户突破 30 万，成为国内最大的吉他 / 尤克里里在线教学平台

2021 年：付费用户超 50 万，累计服务学员超 2000 万

2025 年：累计付费用户达100 万 +，少儿音乐启蒙产品 "音乐壳" 服务 30 万 + 家庭

2.3 TalkAI聚焦**外语口语教育**的垂类场景，通过**AI能力降低口语训练价格**快速占领市场，仅进行场景创新和体验提升的小投入

- 创始人前期打造闪卡工具和Xnote APP，后拓展发布 TalkAI 产品，聚焦知识点记忆巩固的核心配套工具
- 切入成熟的口语教育市场，**通过生成式AI能力形成显著价格优势**抢夺市场，仅进行**小投入的场景创新和体验提升**

AI推理与生成技术正在酝酿新变化，**大力投入模型底层研发不是现阶段ROI最高路径**，在自己熟悉并深耕的领域**拓展用户场景、提升体验**，“高筑墙”是近期应做的事——from Talk AI创始人




2.4 B端对模型能力感知强，高收入行业（当前聚焦码农）更愿为强大模型能力支付高价

2.4.1 海外AI编程业务因人工成本高已进入深度商业化阶段，国内大厂的采纳率同样很高

- AI 编程有两种商业化落地形式：

- **AI 编程应用**：头部产品**Cursor**（隶属Anysphere（2022年MIT团队创立））和**Github Copilot**（隶属微软旗下GitHub，2021年与OpenAI合作推出）通过API调用方式，贡献Anthropic 年化收入合计**14亿美元**，占API收入的45%，**Anthropic整体收入的28%**
- **本地化部署**：企业内部自行部署AI编程工具，调用内外部大模型提供技术支持。Anthropic 其余 API 客户包括 Snowflake、路透社、Canva 等各行各业的企业，通常接入Claude模型用于编程、推理、知识库管理等
- 2023 年底 **OpenAI 在 B 端大模型API 市场的市占率达 50%，Anthropic 仅12%**；而通过发布的Claude Sonnet 3.7、Claude Sonnet 4，**25年H1 Anthropic 市占率达32%位列第一**
- 海外已进入技术成熟 + 商业化阶段，聚焦实现全流程开发自动化。海外头部产品如 **Cursor ARR 达 5 亿美元**，**超60%的企业在编程中使用AI**
- **国内采纳率**：大厂内部高渗透，**腾讯 85% 开发者用 AI 代码助手**，AI 生成代码近 50%；阿里内部 AI 辅助代码生成近 40%；**字节超 80% 工程师用 Trae**。B 端阿里通义灵码在中华财险、哈啰等企业渗透率 30%-70%



2.4.2 Anthropic创立之初即确认B端优先策略，25年实现B端业务市占反超OpenAI

- Anthropic 创立之初确立了**toB优先战略**，与OpenAI 有根本性的战略差异：
 - i. 企业客户对 AI 安全性、合规性、可靠性的需求远高于消费者，与 Anthropic 的安全优先理念高度契合
 - ii. 企业客户更愿意为高质量 AI 服务付费，能**提供更稳定的收入流**
- Anthropic **ARR 达50亿美元**，其中**API收入达31亿美元占比62%**，C端会员订阅占比23%、AI原生编程工具Claude Code收入占比8%，合作分成收入占比18%

年份	ToB 业务发展重点	ToC 业务发展重点	业务比例	
2021	研发奠基，企业合作关系建立	无产品	100% ToB (研发导向)	
2022	技术突破，商业化准备	无产品	100% ToB (准备阶段)	
2023	API 服务上线，企业客户拓展	网页版 + Pro 订阅推出	95%+ ToB, <5% ToC	
2024	分层模型架构，大客户深耕	多端应用拓展	90%+ ToB, <10% ToC	
2025	智能体能力，行业解决方案	专业功能强化	90%+ ToB, <10% ToC	

单位：亿美元					
	收入	AI 方向 CAPEX 总投入	服务器 (GPU/TPU) 投入	数据中心基础设施投入	
2021	0.03	-	-	-	
2022	0.08	5-10	5	极少 (主要租用)	
2023	1	60-70	40	10 - 20	
2024	10	100-150	70-100	30 - 50	
2025	50+	500	300-350	150	


轮次	时间	金额	领投方	
A 轮	2021 年 5 月	1.24 亿美元	Jaan Tallinn (Skype 联合创始人)、Dustin Moskovitz (Facebook 联合创始人)、Eric Schmidt (前谷歌 CEO)	
B 轮	2022 年 4 月	5.8 亿美元	FTX/Alameda Research (提供 5 亿美元)	
战略投资	2023 年 2 月	3 亿美元	谷歌	
C 轮	2023 年 5 月	4.5 亿美元	未披露	
战略投资	2023 年 9 月	最高 40 亿美元(分阶段)	亚马逊	
战略投资	2023 年 10 月	20 亿美元	谷歌 (追加)	
战略投资	2024 年 11 月	40 亿美元	亚马逊 (追加)	
E 轮	2025 年 3 月	35 亿美元	光速创投 (Lightspeed Venture Partners)	
F 轮	2025 年 9 月	130 亿美元	未披露	
最新一轮	2026年1月	计划融资100亿美元	Coatue, GIC, 微软, 英伟达	

1.1.3 AI编程如何落地：原生AI编程应用和B端本地化部署

- 从Anthropic的收入结构，看AI编程的落地形态。据Information，截至25年7月Anthropic的ARR达50亿美元，其中API收入达31亿美元，占比62%，其余为Claude的C端会员订阅占比23%、AI原生编程工具Claude Code收入占比8%以及来自合作伙伴的收入占比18%（Databricks等，共同开发应用）。
- 由此可见AI编程有两种落地形式。1) AI编程应用：第三方开发的AI编程产品。目前头部产品Cursor和Github Copilot通过API调用的方式，贡献Anthropic年化收入合计14亿美元，占API收入的45%，Anthropic整体收入的28%。2) 本地化部署：企业内部自行部署AI编程工具，调用内外部大模型提供技术支持。如Anthropic的其余API客户包括Snowflake、路透社、Canva等各行各业的企业，通常接入Claude模型用于编程、推理、文件搜索与知识库管理等场景。

(亿美元)

图表：Anthropic的ARR收入拆分



注：Cursor和Github Copilot贡献的ARR较这两个产品的ARR高，可能是因为它们还在进行小模型的训练和微调
资料来源：The Information，中信建投

8



中信建投证券
CHINA SECURITIES



1.1.4 为什么AI编程商业化落地快：底层模型能力提升，Claude 3.5是关键转折点

- ✓ 从Anthropic在B端API市场的市占率看：据Menlo Venture，2023年底OpenAI在B端大模型API市场的市占率达50%，Anthropic仅12%，但2024年6月发布的Claude 3.5 Sonnet推动Anthropic市占率增加至24年底的24%，与OpenAI的差距也缩短至10pct；2025年2月和5月发布的Claude Sonnet 3.7、Claude Sonnet 4巩固了Anthropic的领先地位，25年中Anthropic的市占率达32%位列第一。而聚焦到AI编程赛道，Anthropic的市占率达42%，是第二名OpenAI的2倍。

图表：各模型在B端大模型API市场的市占率

整体市场：AI编程驱动Anthropic市占率持续提升

AI编程市场：Anthropic市占率42%位列第一



资料来源：Menlo Venture，中信建投

15



公众号·中信建投研究传媒团队



中信建投证券
CHINA SECURITIES

附录

1. 英伟达重点围绕“物理AI”讲述智能驾驶及具身智能的商业化落地路径



COSMOS: 核心能力

- 生成式物理AI技能
- 对齐语言、图像、3D与动作
- 生成照片级、物理连贯视频
- 交互式闭环模拟
- 推理、分析与预测



2026CES黄仁勋演讲ppt: <https://mp.weixin.qq.com/s/DM-sqm4ZSVrurR7m8ccT2A>

1.1 Vera Rubin架构持续强化性能并降低功耗，为物理AI带来的庞大训练/推理需求服务

核心组件	技术规格与特性	关键提升（较前代）
Rubin GPU	采用 3nm 工艺，集成 3360 亿个晶体管；支持 NVFP4 数据格式，推理性能达 50 PFLOPS	推理性能为Blackwell 的5倍， 训练性能提高3.5倍
Vera CPU	基于88个定制Olympus ARM 内核，集成227 亿个晶体管	数据处理、压缩及编译性能是 Grace CPU 的2倍
NVLink 6	提供 3.6 TB/s 的双向带宽，整架机柜带宽达 260 TB/s	带宽翻倍，支持更大规模的 GPU 集群线性扩展
BlueField-4 DPU	800G数据处理，集成64核Grace CPU，网络性能翻倍	提供6倍计算能力和3倍内存带宽
ConnectX-9 SuperNIC	支持 1.6 TB/s 的 RDMA 带宽	为大规模模型训练和推理 提供极致的网络吞吐量
Spectrum-6/X	硅光子（CPO）交换机，支持 102.4 T 交换容量	功耗效率提升 5 倍，可靠性提升10倍

自动驾驶技术革命：Alpamayo 1

2026年CES上，英伟达发布Alpamayo的开源AI模型家族，强调自动驾驶技术从“感知驱动”转向了“推理驱动”

“物理AI的ChatGPT时刻已经到来，而机器人出租车将是第一批受益者”——黄仁勋

- Alpamayo 1：拥有100亿参数的视觉-语言-动作模型（VLA），引入“因果链”推理机制。在复杂的交通场景中，模型能根据视频输入生成行驶轨迹，还能同步生成“推理迹”，解释其决策背后的逻辑

- **重点强调商业化：**英伟达宣布2025款梅赛德斯-奔驰CLA将是首款搭载完整英伟达AV（自动驾驶）堆栈（包括Alpamayo模型）的量产车型，预计于2026年第一季度在美国上市。此外，英伟达正与JLR、Lucid、Uber以及伯克利DeepDrive等研究机构深度合作，利用AlpaSim仿真框架和包含1727小时真实驾驶数据的“物理AI开放数据集”来加速Level 4级自动驾驶的部署
- **具身智能与物理AI：Cosmos、GR00T与人形机器人**

英伟达推出Cosmos平台和GR00T模型家族，目标为所有物理形态的机器人提供“大脑”

Cosmos：为机器人打造的“世界模型”

- Cosmos是一个专门为物理AI开发的世界基础模型平台，包含了Cosmos Predict、Cosmos Transfer和Cosmos Reason三个核心子模型。Cosmos Transfer和Cosmos Predict通过空间控制输入（如深度图、分割图）生成高保真的物理合成视频，用于训练机器人的策略。Cosmos Reason是具备物理常识和推理能力的视觉语言模型，使机器人能够像人类一样看、听、并理解周围的世界

Isaac GR00T N1.6：用于解锁人形机器人的全身控制能力

- 开源的推理型视觉-语言-动作（VLA）模型，通过集成Cosmos Reason作为核心推理引擎，GR00T N1.6允许人形机器人在行走的同时进行复杂的物体操作，实现了运动与操作的完美融合

1.2 黄仁勋CES上高频强调商业化落地，但其讲述的通过合成数据实现“物理AI”的成本下降进而走通商业化的思路尚待验证

a. 英伟达通过提供从底层芯片到中间层框架的全栈支持，试图定义AI时代的“操作系统”

黄仁勋提出了“计算大重置”的概念，对于商业化而言，这意味着传统基于逻辑规则的软件行业将被基于数据和权重的AI原生应用所取代。英伟达通过提供从底层芯片（Rubin）到中间层框架（CUDA, NIM）的全栈支持，试图垄断这一新时代的“操作系统”

“每15年，行业就会重置一次。新的平台出现，新的应用程序随之产生。这一次，有两个平台转型正在同时发生：不仅是从CPU转向GPU，还有应用程序开发方式的彻底改变。它们不再是被‘编程’出来的，而是被‘训练’出来的。”

b. 智能体系统将作为新的交互界面和企业AI革命的关键

黄仁勋认为，未来的AI不再是简单的检索工具，而是能够自主调用各种专门化模型进行协作的“智能伙伴”，英伟达的商业策略：不仅卖芯片，更通过Nemotron等开源基础模型和NIM微服务，为企业提供构建智能体的“蓝图”

“2025年是‘智能体’模型激增的一年，这些模型能够进行更高层次的推理。……智能体系统就是（未来的）界面。”

c. “物理AI”的经济学：合成数据与成本降维

黄仁勋重点讨论物理AI（机器人、自动驾驶）如何跨越成本壁垒。传统的物理世界训练太慢、太贵。Vera Rubin平台将每个Token的推理成本降低了90%，这对于需要实时处理海量传感数据的机器人和自动驾驶系统来说，是商业化落地的先决条件

“通过使用Cosmos进行物理世界模拟，我们可以生成逼真的、符合物理定律的合成视频，用于训练机器人和自动驾驶汽车。这大大减少了对现实世界训练数据的依赖。”

2. 海内外大厂基础数据信息收集

	亚马逊AWS						
	2022	2023	2024	2025	平均增幅	2022	
总CAPEX投入 AI方向CAPEX投入 (单位：亿元)	1970	1775	3955	7100	53.3%	1697	
服务器（GPU/TPU）投入 (单位：亿元)	-	-	1846	-	-	-	
数据中心基础设施投入 (单位：亿元)	-	-	1582	-	-	-	
算力保有量 等效H100（万片）	-	7.6 括NV芯片数据	30 括NV芯片数据	113.7 括NV芯片数据	286.8%	-	
清洁能源采购（GW）	8.3	5.2	6	-	-15.0%	-	
公司总人数	1608000	1541000	20000 (AI研发人员)	20000 (AI研发人员)	-	221000	

	国内						
	阿里				腾讯		
	2023	2024	2025	平均增幅	2023	2024	
总CAPEX投入 AI方向CAPEX投入 (单位：亿元)	56	489	1048	332.6%	240	691	
服务器（GPU/TPU）投入 (单位：亿元)	-	215	500	132.5%	-	430	
数据中心基础设施投入 (单位：亿元)	-	274	548	99.9%	-	261	
算力保有量 等效H100（万片）	-	NV卡30W 国产卡45W	NV卡46W 国产卡20W	-12.0%	-	NV卡40W 国产卡1W+	
清洁能源采购（GW）	-	-	-	-	-	-	
公司总人数	57859 员人数（含外	49410 员人数（含外	44469 员人数（含外	-12.3%	78009 (研发人员)	76448 (研发人员)	

公司	2020-2022 技术积累与早期探索	2023 基础模型爆发	2024 应用生态构建
OpenAI	战略: 非营利研究 + 微软深度合作, 聚焦 AGI 安全与大模型研发 关键: GPT-3 发布 (2020), DALL·E 2, Copilot (Github)	战略: 消费者应用突破 关键: ChatGPT 爆火, GPT-4 发布, 插件系统尝试, 确立绝对领跑地位	战略: 打造企业级OS与多模态应用 关键: GPT-4o (实时全能), Sora (视频), GPTs Store (应用商店) 发力
	2020 年 7 月, 获得微软10 亿美元投资, ChatGPT 5 天用户破 100 万, 2 个月月活破亿	2023 年web端MAU1.5 亿	2024 年web端MAU2.6 亿
Google	战略: DeepMind 与 Google Brain 并行, 强化学习 + Transformer 双轮驱动 关键: Meena, LaMDA (未公测), DeepMind 专注 AlphaFold 等科学领域	战略: “Code Red” 紧急防御,与 OpenAI 正面竞争 关键: 仓促推出 Bard (后更名), 合并 Google Brain 与 DeepMind, 发布 Gemini 1.0	战略: Gemini 全面融入 Google 全产品线 AI 重塑 关键: Gemini 1.5 Pro (超长上下文), SGE (搜索生成体验) 全量上线
	2020-2022 年 AI 累计投入超 400 亿美元, DeepMind 与 Google Brain 各占 50%	Bard2023 年 12 月月活数9000万	2024 年web端MAU 0.5亿
Amazon	战略: 云计算+机器学习服务 关键: AWS SageMaker 持续迭代, Alexa 语音助手 (传统AI)	战略: 构建企业级生成式 AI 生态 关键: 推出 Amazon Bedrock , 投资 Anthropic (Claude) 以补齐模型短板	战略: 赋能电商业务, 强化 AI 竞争力 关键: 推出 Amazon Q (企业级助手), 强化 B 端客户的数据安全与合规
	截止2022年底, SageMaker 拥有超 10 万家企业客户, 截至 2022 年底, Alexa 设备累计激活超 4 亿台	2023 年底, Bedrock 服务10000+企业客户, 累计 API 调用量超 1 万亿次	Amazon Q (企业助手) 在2023年12月达到350万+企业用户注册, 2024年1月月活数220万+
Meta	战略: PyTorch 生态与元宇宙 关键: FAIR 实验室发表大量论文, 重点仍在 VR/AR 投入。	战略: 开源社区力量对抗闭源 关键: 推出 LLaMA 系列, 确立 “开源模型盟主” 地位, 利用社区力量对抗闭源巨头	战略: 开源 + 应用双轮驱动 关键: Llama 3 (性能对标 GPT-4), AI助手植入 WhatsApp/Instagram
	2020 年发表论文186 篇, 2021 年发表论文207 篇, 2022 年发表论文223 篇, GitHub 星标超60,000星 (2022 年底)	LLaMA系列模型2023 年累计下载量超 3000 万次, GitHub超12,000 个基于 LLaMA 的开源项目	2024 年 12 月 MAU6 亿 (全球)
Tesla	战略: 视觉感知与自动驾驶 关键: FSD Beta 持续测试, Dojo 超算中心建设, 去除雷达坚持纯视觉。	战略: “端到端” 神经网络, AI 机器人领域 关键: FSD v12 (端到端大模型上车), 发布 Optimus人形机器人原型, 算力储备大增	战略: 自动驾驶技术商业化, 拓展 AI 应用 关键: FSD 监督版大规模推送, Optimus Gen 2 进工厂实习, 概念强化
	FSD 个人订阅用户数10 万, 月活数8 万	FSD 年均个人订阅用户数40 万, 2023 年 12 月月活数32 万	FSD 年均个人订阅用户数150 万, 2023 年 12 月月活数120 万
字节跳动	战略: 强化内容生态 AI 能力 关键: 抖音/TikTok 算法优化, AIGC 辅助特效 (AILab), 火山引擎云服务建设	战略: 快速跟进与多线赛马 关键: 推出 “豆包” (Doubao) 及云雀大模型, 内部多团队开发 AI 应用 (Cici, ChitChop)	战略: 构建全栈 AI 布局, 超级应用生态 关键: 豆包 App 日活破亿, 发布 AI 应用; 发布多模态模型 Doubao Video
	2020 年 8 月, 抖音 + 抖音火山版 DAU 超 6 亿, 2022 年 9 月, 全球月活跃用户超 10 亿	2023 年 12 月豆包累计注册用户数0.2亿+, 2023 年 app端 MAU 0.1亿	2024 年 12 月豆包累计注册用户数0.5亿+, 2024 年 app端 MAU 0.5亿

阿里巴巴	战略: 达摩院进行前沿探索 关键: M6 大模型 (参数规模探索), 城市大脑, 电商推荐系统	战略: 云智一体 关键: 阿里云发布 “通义千问”, “所有产品都值得用大模型重做一遍”, 钉钉率先接入	战略: 开源与B端深耕 关键: Qwen (通义千问) 开源 HuggingFace; Qwen 2.5 发
	M6 大模型 2021 年 1 月达百亿参数, 5 月达万亿参数, 10 月达10 万亿参数 (稀疏模型)	2023 年 app端 MAU 42万	2024 年 app端 MAU 248万
腾讯	战略: 游戏与社交AI 关键: 绝艺 (围棋 AI), 广告推荐算法, 医疗 AI 探索	战略: 混元大模型跟随 关键: 发布 “混元” 大模型, 保持克制, 在会议、文档等办公场景低调内测	战略: 构建 C 端 AI 入口,连接成 关键: 元宝 App 上线 (依托公态); 混元文生图/3D能力落地; 腾讯云推出RAG解决7
	2020 年绝艺胜率 99.8%	2023 年 10 月, 接入业务扩展至180+	2024 年 app端MAU 740万

3. 海内外头部大厂招聘方向从 “研究型科学家” 逐渐转向 “商业化落地专家”

- 初期招聘倾向：偏好能通过堆砌算力和数据规模创造奇迹的研究型科学家，数学等基础学科方向更多
 - 中期招聘倾向：AI研究员开始向机器人学、多模态感知和端到端控制领域迁移
- 特斯拉的人才流失到Sunday Robotics，以及Meta重金挖掘感知团队（Perception Team），都是这一趋势的体现
- 25年招聘倾向：从 “模型训练工程师” 转向 “智能体编排专家”
 - 2025年是 “Agentic Workflows” 的元年，人才需负责构建让多个专用AI模型相互协作、调用外部工具、并进行自我修正的复杂系统

公司	2023 年	2024 年	2025 年
OpenAI	11月：Altman 离职 / 重返 + 董事会重组	6月：收购远程协作AI初创公司 Multi	9月：11亿美元收购Statsig（创始人任 CTO） 10月：收购理财APP Roi 12月：收购AI工具平台Neptune
Google	4月：合并 Google Brain 与 DeepMind 为 “Google DeepMind”，Demis Hassabis 任 CEO、Jeff Dean任首席科学家	8月：27亿美元与 Character.AI战略合作	4月：Gemini负责人Sissie Hsiao（1980 年, 历任微软产品经理、谷歌AI语音助手业务）辞职, Josh Woodward（1983 年, 历任牛津研究员，谷歌教育/文档工具业务）接任
AWS	4月：Swami Sivasubramanian为ML部门全球副总裁，负责 Bedrock、SageMaker等生成AI核心服务研发与商业化	3月：AI业务副总裁Baskar Sridharan离职 6月：生成式AI全球副总裁 Vasi Philomin离职，从	12月：首席科学家Rohit Prasad（1975 年, Alexa 首席科学家）离职, Peter DeSantis（1975年, 构建AWS计算、存储、网络核心产品线）牵头新AI部门，Pieter Abbeel（1977年, "AI 创业教

		Adapte挖多位联创加入AI部门	父”，公司被亚马逊收购）任AGI团队负责人
Tesla	8月：AI芯片团队并入Ashok Elluswamy的Autopilot部门	10月：Dojo 团队核心成员Eric Quinnell 离职（主导Dojo Fabric 研发）	8月：Dojo 团队解散，负责人Peter Bannon离职 擎天柱主管Milan Kovac、软工副总裁David Lau离职
Meta	—	2月：前OpenAI资深研究员Alec Radford（GPT-3/GPT-4）加入 Meta，任 FAIR 实验室生成式 AI 首席研究员	6月：143 亿美元入股 Scale AI（49% 股份），Alexandr Wang任首席AI官，成立 Superintelligence Labs 10月：裁撤 AI 部门 600 人 11月：首席AI科学家Yann LeCun宣布离职 12月：收购 Manus，创始人肖弘任副总裁
阿里巴巴	6月：张勇卸任集团 CEO，吴永明接任；蔡崇信任董事长	7月：通义千问技术负责人周畅离职（10月加入字节）	4月：通义实验室薄列峰（应用视觉）、鄢志杰（语音）离职 12月：云计算CTO / 通义实验室负责人周靖人成阿里合伙人
字节跳动	年中：从AI Lab/AML/搜索团队抽调人手组建Seed（豆包大模型）团队，向梁汝波汇报	4月：AI Lab整体并入Seed 团队，李航转任顾问 10月：挖来阿里周畅及其团队加入Seed	2月：前 Google DeepMind 副总裁吴永辉加入任 Seed 基础研究负责人 7月：Seed视觉多模态负责人杨建朝“暂休”，周畅接棒 10月：吴永辉成Seed负责人（朱文佳汇报线调整至吴永辉）
腾讯	上半年：TEG 大数据部门胜出，组建“混元大模型团队”，蒋杰（TEG 副总裁）负责	3月：腾讯混元大模型团队负责人蒋杰晋升TEG 高级副总裁，负责AI技术商业化落地	9月：前OpenAI研究员姚顺雨加入任首席AI科学家 12月：重组AI部门，成立“AI 基础设施”团队，姚顺雨牵头 12月底：腾讯AI Lab副主任、科学家俞栋离职（学术+产品）

4. Anthropic 成立背景及营收情况

- 成立背景

Anthropic 成立于**2021 年**，由前 OpenAI 核心成员达里奥·阿莫迪 和丹妮拉·阿莫迪 兄妹联合创立，创始团队还包括十多名前 OpenAI 核心成员，他们都是 AI 安全领域的顶尖专家。创立的原因是与

OpenAI 在**AI 安全优先级**上的根本分歧：2019 年 OpenAI 转型 "利润上限" 公司并与微软签订独家计算协议，达里奥团队认为这会让 OpenAI 过于侧重短期商业化，忽视长期 AI 安全风险。

Anthropic 从创立之初就确立了 **ToB 优先战略**，这是其与 OpenAI 最根本的战略差异。原因如下：

- a. 企业客户对 AI 安全性、合规性、可靠性的需求远高于消费者，与 Anthropic 的安全优先理念高度契合
- b. 企业客户更愿意为高质量 AI 服务付费，能提供更稳定的收入流

年份	ToB 业务发展重点	ToC 业务发展重点	业务比例		
2021	研发奠基，企业合作关系建立	无产品	100% ToB (研发导向)		
2022	技术突破，商业化准备	无产品	100% ToB (准备阶段)		
2023	API 服务上线，企业客户拓展	网页版 + Pro 订阅推出	95%+ ToB, <5% ToC		
2024	分层模型架构，大客户深耕	多端应用拓展	90%+ ToB, <10% ToC		
2025	智能体能力，行业解决方案	专业功能强化	90%+ ToB, <10% ToC		

• Anthropic 融资情况

轮次	时间	金额	领投方	
A 轮	2021 年 5 月	1.24 亿美元	Jaan Tallinn (Skype 联合创始人)、Dustin Moskovitz (Facebook 联合创始人)、Eric Schmidt (前谷歌 CEO)	
B 轮	2022 年 4 月	5.8 亿美元	FTX/Alameda Research (提供 5 亿美元)	
战略投资	2023 年 2 月	3 亿美元	谷歌	
C 轮	2023 年 5 月	4.5 亿美元	未披露	
战略投资	2023 年 9 月	最高 40 亿美元(分阶段)	亚马逊	
战略投资	2023 年 10 月	20 亿美元	谷歌 (追加)	
战略投资	2024 年 11 月	40 亿美元	亚马逊 (追加)	
E 轮	2025 年 3 月	35 亿美元	光速创投 (Lightspeed Venture Partners)	
F 轮	2025 年 9 月	130 亿美元	未披露	
最新一轮	2026年1月	计划融资100亿美元	Coatue, GIC, 微软, 英伟达	

• Anthropic 收入和投入情况

单位: 亿美元	收入	AI 方向 CAPEX 投入	服务器 (GPU/TPU) 投入	数据中心基础设施投入	
2021 年	0.034	-	-	-	
2022 年	0.079	5 - 10	3 - 5	极少 (主要租用)	
2023 年	1	60 - 70	40	10 - 20	
2024年	10	100 - 150	70 - 100	30 - 50	
2025年	50 +	500	300 - 350	150	

注：2025 年底，Anthropic 宣布了一项重大的战略转型：从单纯的“云租户”转向深度参与基础设施建设。

- \$50B 投资计划： Anthropic 宣布在德克萨斯州和纽约州建设专为 Claude 模型优化的大型数据中心。
- 资金来源： 主要通过 Amazon (追加投资)、Google 以及 2025 年 11 月与 Nvidia/Microsoft 达成的战略协议（包括 Nvidia 投入的 100 亿美元硬件支持）。

5. OpenAI 算力投入与营收拆解

- 融资情况追踪

融资时间	融资轮次	融资金额	主要出资方
2021 年 1 月	二级市场融资	未披露（约数亿美元）	Tiger Global Management, Bedrock Capital, Andreessen Horowitz
2021 年 7 月	企业战略投资	20 亿美元	微软（Microsoft）
2022 年 1 月	Series A	2.5 亿美元	微软、老虎基金、A16z、YC Research、红杉资本
2023 年 1 月	企业战略投资	100 亿美元	微软（Microsoft）
2023 年 4 月	风险投资轮	3 亿美元	Tiger Global, 红杉资本（Sequoia）, Andreessen Thrive Capital, K2 Global, Founders Fund
2024 年 10 月	战略融资	66 亿美元	Thrive Capital（领投）, 微软, 英伟达（Nvidia）（SoftBank）, 富达（Fidelity）, Khosla Ventures, Capital
2024 年 10 月	债务融资（循环信贷）	40 亿美元	摩根大通、花旗、高盛、摩根士丹利、桑坦德银行
2025 年 3 月	战略融资	400 亿美元	软银集团（SoftBank，领投）, 微软, Magnetar Capital Management, Founders Fund, 阿联酋 MGX 等
2025 年 10 月	企业少数股权投资	225 亿美元	软银集团（追加投资）

- 21~25年openai 算力投入追踪

年份	算力投入 金额 (亿美元)	主要用途	数据来源
2021 年	3-5	用于GPT-3后续版本优化及早期多模态模型研发，算力规模约10 ²² FLOPS级别，依赖英伟达A100 GPU集群	1. 微软Azure合作披露：2021年为OpenAI部署Voyager超级计算机（264个Azure ND A100 v4节点），项目投入约4亿美元 2. 《OpenAI的软硬件生态布局与进展》
2022 年	8-12	支撑GPT-4早期训练与推理测试，算力投入较2021年翻倍，	1. Glenn Klockwood科技博客披露OpenAI 2022年专属超级计算机建设信息

		涵盖超级计算机核心硬件采购及网络基建，剩余部分为短期算力租赁的运营性支出	
2023年	20-25	ChatGPT上线后推理算力需求激增，全年消耗约3.8万颗A100 GPU，含训练端2.5万颗集群运维成本；主要用于GPU集群扩容、数据中心配套设施建设，推理端短期租赁支出占比首次超过30%	1. Gizchina报道：2023年微软对OpenAI追加100亿美元投资，其中40%用于算力基础设施 2. CSDN博客《烧数亿美元、耗上万颗英伟达GPU》披露ChatGPT训练硬件成本
2024年	80-90	用于GPT-4.5规模化训练（消耗8-10万颗H100 GPU）及“星际之门”项目前期筹备，推理端全球节点扩张持续推进；涵盖多区域推理节点基建、H100 GPU批量采购及数据中心土地规划成本	1. 汇丰银行2025年12月研报《AI算力军备竞赛：OpenAI的长期投入与盈利挑战》 2. 澎湃新闻2025年9月：OpenAI 2024年现金消耗超80亿美元，核心用于算力基础设施 3. 证券时报披露：微软与OpenAI拟斥资超1000亿美元建设“星际之门”数据中心，2024年启动前期投入
2025年	200-250	“星际之门”项目正式启动核心驱动投入量级跃升，含6GW AMD GPU部署首期成本、英伟达H100集群扩容（35万颗规划落地30%）及多模态大模型（GPT-5、Sora）训练算力	1. 汇丰银行2025年12月研报：2025-2030年OpenAI云和算力成本达7920亿美元，年均超1500亿美元 2. 光明网：OpenAI与软银、甲骨文联手“星际之门”项目2025年初始投资1000亿美元，年度实际投入拆分后为180-220亿美元 3. 澎湃新闻：每部署1GW 算力成本500亿美元，25年OpenAI 2GW算力部署，年度投入1000亿美元（伙伴分摊，OpenAI占比20%）

5.1 OpenAI 营收模式拆解

2025年营收\$125亿，70%收入来自C端（OpenAI CFO Sarah Friar，2025年9月），即\$87.5亿，推测全球付费用户约3500万（按\$250/年·人测算）

2026年预期营收需实现近3倍增长达到\$350亿（C端收入需突破\$240亿）以支撑估值与融资，全球付费用户需增加至1.2亿（26年竞争加剧，按\$200/年·人测算）

套餐名称	定价（美元 / 月）	计费方式	核心访问权限
免费版 (Free)	\$0	永久免费	GPT-5 基础访问，基础消息 / 文件 / 分析额度
Plus	\$20	按月计费	免费版全部内容 + 扩展 GPT-5 访问 + 提升消息 / 文件 / 图像生成限制
Business	\$30（按月）	每用户 / 月，支持按年优惠	Plus 全部内容 + 协作功能 + GPT-5 无限制消息 + 连接控制台
	\$25（按年）		
Pro	\$200	按月计费	Plus 全部内容 + GPT-5 Pro 访问 + 高级推理 + 无限制消息支持
Enterprise	定制报价		

5.2 OpenAI 在每年千亿级CAPEX下，需平均新增\$650亿收入以达成盈亏平衡，短时间无法达成

- 显卡价格波动追踪（英伟达H100为例）：

时间节点	市场阶段	价格估值 (单卡/美元)	H100占比	关键事件与市场状态
2022年 9-10 月	产品发布/上市	30k - 33k	5%	H100正式投产。此时市场尚未完全爆发，主要供应给核心云计算大客户（如微软、谷歌），公开市场流通极少
2023年 Q1-Q2	ChatGPT爆发期	35k - 40k	20%	ChatGPT引爆生成式AI热潮。全球科技巨头疯狂抢购，订单排期长达6个月以上，“缺芯”恐慌开始蔓延
2023年 Q3-Q4	极度紧缺/炒作巅峰	40k - 50k+	35%	供需矛盾达到顶点。eBay等二级市场上现货被炒至\$45,000以上。国内因禁售令影响，走私渠道价格极其混乱且高昂
2024年 Q1-Q2	高位盘整	30k - 40k	45%	供应链（CoWoS封装产能）开始改善，交付周期缩短至3-4个月。价格虽仍在高位，但那种“有价无市”的疯狂程度稍有缓解
2024年 Q3-Q4	新旧交替/缓慢回落	25k - 30k	55%	英伟达发布H200及下一代Blackwell（B200）消息，导致H100需求略有分流。现货供应逐渐充足，价格回归理性区间
2025年 Q1-Q2	常态化供应	22k - 26k	60%+	随着Blackwell系列开始出货，H100转为次旗舰。二手市场和租赁价格大幅下降（租赁价从高峰期\$8/时降至\$2-3/时）

- 盈亏平衡计算公式：

$$R_{needed} = \frac{(CAPEX \times \text{折旧率}) + \text{年化运维成本 (OPEX)}}{\text{业务边际贡献率}}$$

参数设定

- 资产折旧率：服务器及GPU生命周期短，AI领域由于算力迭代快，通常采用**5~6年**折旧

亚马逊财报：

- 于 2024 年 1 月 1 日起，将服务器的使用寿命从5年延长至6年
- 自 2025 年 1 月 1 日起，将部分服务器及网络设备的使用寿命从6年调整为5年

谷歌财报：

- 服务器、网络设备等硬件采用 “直线折旧法” ，即资产总成本在预计使用寿命内平均分摊，折旧费用固定
- 服务器和网络设备折旧时间：6年
- 运维成本 (OPEX)**：包括巨大的电力消耗（AI 数据中心电费占比极高）、散热、固保、网络带宽以及高昂的人才薪酬。通常设定为CAPEX的**20%~30%**
- 边际贡献率**：对于 SaaS 或云服务，**边际利润较高（约60%~80%）**；对于电商（阿里、字节）或硬件（特斯拉），综合利润率较低（约0%~30%）

- 根据已有算力租赁合同及外部报告数据，OpenAI年投入约\$1000亿AI CAPEX：

- 年化支出 (Cost Side):
 - 折旧 (5年平摊)：\$200 亿
 - 运维与电力 (25% CAPEX)：\$250 亿
 - 合计每年新增硬支出：约 \$450 亿**
- OpenAI业务增长需求属于高毛利路径（云服务/软件），边际贡献率为70%（最乐观估计），需每年新增\$643亿收入

- OpenAI 26年1月17日公开宣布在免费和GO版本中测试广告

6. openai与google发布会追踪

时间	OpenAI		Google	
	AI定位	舆论反馈	AI定位	舆论反馈
2022.11.30	发布 ChatGPT，定位“对话式 AI 助手”，基于 GPT-3.5 优化，主打自然语言连续交互、上下文理解能力	舆论高度正面 ：引爆全球关注，上线 5 天用户破百万，被视为生成式 AI 交互范式革		

		新，开启 AI 大众化热潮		
2023.2.8			推出Bard，定位“搜索增强型对话助手”，对标 ChatGPT，回避AGI表述	灾难性负面：演示出现事实错误，股价暴跌8%，市值蒸发约1000亿美元，被嘲“仓促应战”
2023.3.14	发布GPT-4，明确称为“AGI的早期版本”，强调多模态能力与人类水平推理	全球狂热正面：被视为AI里程碑，OpenAI确立行业领导者地位，舆论一片赞誉		负面余波未平，对比GPT-4的亮眼表现，舆论质疑其技术储备不足
2023.11.7	举办首届开发者大会（DevDay），推出GPTs，强调“人人可定制AI”，构建AGI生态，暗示AGI路径清晰	好评如潮：开发者热情高涨，GPTs被视为AI民主化重要一步，舆论持续正面		
2023.12.6			发布Gemini 1.0，定位“原生多模态模型”，对标GPT-4，强调“多项测试领先”，淡化AGI叙事	中性：初期因仅上线Nano版本遭质疑，但被视为谷歌反击的开始，舆论逐步回暖
2024.5.14			举办I/O大会，更新Gemini（整合PaLM 2），推出Project Mariner（支持10项并行任务），定位“实用型AI助手”，持续能力对标	偏正面：用户认可其与谷歌生态的深度整合，功能实用性获好评，舆论反馈稳步改善
2025.1.9	举办连续12天发布会，推出o系列模型，o3模型被称为“接近AGI标准”，强调复杂决策和高端问题解决能力	舆论分化：技术圈高度评价其技术突破，但普通用户对复杂性感到困惑，负面声音开始浮现		
2025.3.26			发布Gemini 2.5 Pro，定位“地表最强AI推理模型”，在多项基准测试中全面超越 OpenAI o3-mini，聚焦推理能力提升	高度积极：全球热议，被视为谷歌重夺技术主导权的关键一役，舆论一片赞誉

2025.8.8	发布GPT-5，宣称从“大学生水平”跃升至“ 博士级专家能力 ”，强调是“通向AGI的关键一步”，AGI押注态势明确	极度恶化 ：48小时内用户发起“反抗运动”，出现图表错误、功能倒退等问题，舆论从失望转向愤怒，口碑崩盘		
2025.11.18			发布Gemini 3.0（无线下发布会，线上同步），定位“ 百万上下文+全链路Agent ”，补齐AI最后一块拼图，聚焦实用性和生态整合， 继续淡化AGI	正向反馈超预期 ：惊艳全场，科技圈普遍好评，OpenAI CEO Altman公开点赞，舆论口碑达到峰值

7. 英伟达CES展会内容

• 推理上下文内存存储平台：AI原生存储

英伟达在CES 2026上推出的“推理上下文内存存储平台”，作为AI原生的存储基础设施，利用BlueField-4 DPU和Spectrum-X网络，扩展了GPU的内存容量。该平台可将每秒生成的Token数量提升5倍，同时将总持有成本（TCO）下的性能提升5倍，电力效率同样提高5倍。通过在整个机架级集群中共享和重用KV Cache，该存储平台使得多轮推理的响应速度更快，并支持长文本、多步骤推理的智能体实现高效扩展

• 游戏与创作：DLSS 4.5与RTX AI PC的全面进化

- 英伟达在传统的个人计算和游戏领域也带来了重磅更新，宣布推出DLSS 4.5，这是神经渲染技术的又一巅峰
- DLSS 4.5引入了“动态多帧生成”和“6倍多帧生成模式”。通过采用第二代Transformer模型进行超分辨率处理，DLSS 4.5能够显著减少画面闪烁和重影，提供极其稳定的图像质量。其6倍帧生成模式旨在让RTX 5090等顶级显卡在4K分辨率下驱动240Hz的电竞显示器，实现极致流畅的游戏体验
- 英伟达还展示了在DGX Spark桌面超级计算机上运行的本地个人AI代理，展示了小型化超级计算在处理复杂逻辑任务时的巨大潜力

8. 字节seed研究员访谈

8.1 一阶段沟通内容：

1、关于豆包是否在内部降级：未降级反而重要性还在提升，腾讯下场后人才竞争更加激烈了。内部认为AI泡沫已说2、3年但大厂的业务模式足以支撑AI支出。不过对OpenAI这种all in的公司觉得有一定风险

2、关于内部薪资：今年入职的应届博士生（98、99年为主）5~6百万已常见，他自己手下的应届生接近8位数（这两年倒挂明显，内部不认可的就“转会”）；也说姚顺雨的薪资上亿是肯定的

3、豆包留存的讨论：内部觉得只要DAU足够高且持续增长就不担心留存

4、关于行业生态现状：

- 目前来看确实是和其他传统行业不太一样，**AI是应用层蛋糕小，卖铲子的蛋糕大**（基础模型和芯片），且内部判断国内单纯allin模型或应用的公司大概率活不长久
- OpenAI和gemini不存在代差了（其实模型已被google超越，人才量级都不对等），他们目前是尝试通过记忆、个性化等功能留住用户，但不得不承认openai已经形成了品牌认知（大厂聚焦挖其内部人才）

8.2 二阶段沟通内容：

1、高薪博士做什么：对于高薪博士的招聘，内部前两年就有但今年力度更大。所安排其做的工作大部分是公司的主线任务，即大模型训练、调优等

2、为什么给高薪：内部研发人员是会分配一定数量的卡的，**卡的成本远高于人**，而越好的博士成功率越高（**聪明博士和普通研发胜率差超50%**），比如**GPU卡成本10~30w/天**，而人工资只是**10w+/月**，总账逻辑也是合理的

3、各家模型能力：字节、阿里、deepseek属于第一梯队，KIMI、阶跃星辰等属于二梯队，腾讯动作慢，介于二三梯队之间。**基础模型能力是不受公司主营业务影响的**，而是要冲国际统一标准的榜单（比如数学解题等维度）；但因为**业务端会提应用侧需求**，所以会有不同能力的体现

4、海外大厂动态：meta第一波收购动作引进的Alexandr Wang甚至不是搞算法的，内部觉得**纯粹是想赶走Yann LeCun团队**；第二波高溢价收购manus是因为老板**认可agent方向**，但内部孵化agent团队或新招人都是极高成本且容易失败，不如**买入成熟团队**


5、其他有用信息：

- 智谱是在竞争中掉队的，所以最先出现财务压力冲刺IPO
- 到了openai和google deepmind这种层级，**人才差距已经不大了**，不存在openai是最天才的那一批，只是**openai更偏自下而上机制更灵活**，而**deepmind还是大厂逻辑自上而下**

9. 美国国家级投资政策追踪

计划名称	发布时间	资金性质	资金投入计划
美国 AI 行动计划	2025年1月政策令启动 2025年7月计划发布	政府资金 + 私营资本（主导）	470亿美元：政府 AI 科研基础设施（国家实验室、平台） 3200 亿美元：私营 AI 大模型研发与算力扩张（微软、亚马逊等）
星际之门 (Stargate) 计划	2025 年 1 月 21 日	100%私营资本（OpenAI + 软银 + 甲骨文 + MGX 合资企业）	3000亿美元：AI数据中心建设及算力供应（与甲骨文） 1000亿美元：新增AI数据中心集群建设（软银主导） 500亿美元：清洁能源配套项目 300亿美元：国家级超级计算网络搭建 100亿美元：AI人才培养 100亿美元：AI安全与监管体系建设
宾州能源与创新峰会投资计划	2025 年 7 月 15 日	100%私营资本	400 亿美元：AI 数据中心建设（与亚马逊、谷歌等） 560 亿美元：能源基础设施升级 10 亿美元：AI 研发与人才合作项目
创世纪计划 (Genesis Mission)	2025 年 11 月 24 日	政府引导（能源部牵头）+ 24 家企业参与（主导）	50亿美元：私营部门配套算力支持（英伟达、AMD 供，用于超级计算集群升级） 20亿美元：联邦科学数据集整合 5亿美元：关键科研领域AI应用 3.2亿美元：“美国科学云”与模型联盟建设 3亿美元：科研人才协同培育

10. 应用追踪



11. 腾讯财报电话会追踪 + 内部交流会情报

“在算力方面，我们已经从主要关注训练算力转向了推理算力。如果未来有大量的 AI 应用，如 Agent 进入爆发期，全行业的推理算力储备将面临考验。” ——腾讯 2024 年第三季度财报电话会

“关于大语言模型（LLM）训练的问题，这属于第二优先级，因为训练通常需要更高端的芯片。幸运的是，过去几个月业内观念出现了转变，人们开始摆脱美国科技公司所谓“规模定律”

(ScalingLaw)，即必须持续扩张训练集群的思维。但现在我们发现，即使使用较小的集群，也可以取得不错的训练效果。这说明，模型训练不一定非要依赖超大规模集群。” ——腾讯 2025 年第一季度财报电话会

腾讯超过 90% 的程序员正在使用 AI 编程助手 CodeBuddy 辅助写代码。2025 年，全公司有 50% 的新增代码由 AI 辅助生成——相当于程序员每写两行代码，就有一行是在 AI 帮助下完成的。AI 不仅写代码，还“审代码”。在代码评审环节，AI 参与度高达 94%。其中 28% 的代码问题由 AI 直接发现并被采纳，推动有效问题检出量提升 44%。在 AI 的辅助下，平均编码时间缩短 40%，整体研发效能提升超 20%。——《2025 腾讯研发大数据报告》

“我们观察到目前的 Agent 产品在处理复杂任务时，错误率会随着步骤的增加而指数级放大。对于微信这样拥有数亿用户的产品，我们对准确率和用户体验的要求极高。” ——腾讯 2025 年第三季度财报电话会

国内 AI 放量的核心影响因素是算力，尤其是推理算力不够。若 agent 广泛普及，所需算力将大幅增加，国内算力可能无法满足全面铺量需求。——腾讯 AI 内部交流会

AI 发展是一个长期过程，目前仍处于早期阶段，scaling law 远未到头，后续在预训练、强化学习优化模型等方面还有很大进步空间。——腾讯 AI 内部交流会

腾讯内部使用 code Buddy 软件写代码，AI 贡献的代码率达 50%，要求所有人员必须使用。——腾讯公关部交流会

目前国内 AI 产品在 c 端落地存在问题，演示效果与实际可用性差距大，agent 产品的正确率不高，复杂任务错误率易放大，微信上 agent 功能今年可能不会成熟。——腾讯 AI 内部交流会

12. 软银AI投资动作追踪

资金渠道	具体构成	金额 / 占比	用途
资产套现	清仓英伟达股份	约 58 亿美元	OpenAI 投资、DigitalBridge 收购、星际之门配套
战略收购协同	DigitalBridge 收购配套资金	约 40 亿美元（企业价值）	整合数据中心、光纤等基础设施，支撑 AI 算力网络
股权与联合投资	软银自有资金 + 协调第三方联合投资	软银直接投 OpenAI 累计约 300 亿美元，联合投资约 110 亿美元	OpenAI 股权及“星际之门”股权出资（软银初始约 190 亿美元）
债务融资	银团贷款、项目债等	“星际之门” 90% 资金（约 4500 亿美元总规模）计划通	项目基建（数据中心、发电设施）

13. 当前AI领域的巨头融资模式也在从自有现金到利用杠杆，系统性风险潜伏

1. 2025 年下半年AI 巨头正从“现金储备模式”转向“债务驱动模式”

- Meta 发行 **300 亿美元**债券
- Oracle 为了资助其与 OpenAI 的合作及云基建，**一次性发债 180 亿美元**

巨头公司	2025-2026 预测资本开支 (\$bn)	融资行为转变
Amazon	150 - 160	转向公募债券市场以弥补自由现金流缺口
Microsoft	100 - 120	资本密集度达到营收的 45%-57% 的历史高位
Meta	50 - 60	史上最大规模非并购发债，杠杆比例显著上升
Oracle	30 - 40	信用违约掉期 (CDS) 价格飙升，市场对债务违约风险敏感度增加

2. 宏观金融指标的预警信号

- **债券发行高峰与利息负担**：2025 年发行的大量 AI 专项债将在 2026 年进入利息支付高峰期。如果届时利率受关税等宏观因素影响保持高位，科技企业的利润将被利息支出影响
- **集中度风险**：AI 相关行业（半导体、公用事业、云技术）目前占据了标杆投资级债券指数的 18%。高度集中的风险意味着，任何单一龙头的财报爆雷都可能引发指数级的集体下修

14. 构建商业闭环的能力、自有现金流稳健性及利用关联业务进行低风险扩张的策略相比技术发明及早期激进投入更能提升成功率

- **构建商业闭环的能力、自有现金流稳健性及利用关联业务进行低风险扩张的策略**带来更高成功率
- 技术领先性和激进的早期投入并非通向最终胜利的门票，反而可能成为沉重的财务负担

成功要素	成功率统计	定义	历史典型代表
构建商业闭环/生态壁垒	100% (9/9)	通过技术、协议或渠道锁定用户，形成排他性竞争优势	AT&T (长途网络/许可度), IBM (软硬件捆绑)
依赖自有资金/内部造血	88% (8/9)	拒绝被外部短期资本绑架，具备独立穿越周期的现金流能力	标准石油 (极致成本控制), 通用电气 (并购后止损)
	88% (8/9)		

关联业务转型/跨界进入		并非白手起家，而是利用既有资源、渠道或品牌进行二次曲线跃迁	亚马逊 (书店物流->云服务), 纽约中央铁路 (航运->铁路)
早期技术创新/激进投入	33% (3/9)	在研发初期进行大规模重资产投入，构建先发优势	布里奇沃特运河 (基建投入), 亚马逊 (服务器/云投入)
是否为技术先驱/发明者	22% (2/9)	首个提出概念或发明核心技术。统计显示，先发者多成为“先烈”	仅布里奇沃特与贝尔电话为显著先驱
依赖外部融资输血	11% (1/9)	长期依靠VC或债权生存。绝大多数大赢家拒绝被资本绑架	仅亚马逊在早期亏损阶段深度依赖VC/发债

行业	成功企业	是否为技术先驱	早期在技术创新上激进投入	依赖外部融资输血	由关联业务转型进入	构建商业生态壁垒
英国运河	布里奇沃特运河	✅ 是 (第一条工业运河)	✅ 是 (重资挖掘运河，属必须基建)	❌ 否 (依靠变卖家产+私人借贷)	✅ 是 (行业开创者，但(围绕自家煤矿运输需求)	✅ 是 (煤矿+运闭环)
美国铁路	纽约中央铁路 (范德比尔特)	❌ 否 (那是史蒂芬森的事)	❌ 否 (只买通车的路，不自己开荒)	❌ 否 (厌恶发股，用航运现金买)	✅ 是 (航运巨头跨界)	✅ 是 (港口+铁断)
电报	西联汇款	❌ 否 (那是莫尔斯的事)	❌ 否 (只收购，利用铁路路权)	❌ 否 (主要靠股票置换与内生增长)	✅ 是 (地产/借贷商跨界整合)	✅ 是 (电报按字电子汇款)
电话	AT&T (贝尔)	✅ 是 (拥有核心专利)	✅ 是 (必须铺设长途铜缆构建壁垒)	❌ 否 (摩根财团并购，帮助AT&T发债，后成为公共事业)	❌ 否 (后期变为垄断巨头，但出身是先驱)	✅ 是 (前期长达摩根接手许可度假自然垄断)
电力	通用电气 (GE)	❌ 否 (整合了爱迪生，但本身是资本产物)	❌ 否 (摩根介入是为了停止砸钱/专利战)	❌ 否 (摩根财团并购+信用背书，共享专利)	✅ 是 (金融资本主导的整合)	✅ 是 (设备+电业链)
石油	标准石油	❌ 否 (那是德雷克上校的事)	❌ 否 (坚决不挖油，只做炼油)	❌ 否 (依靠转运利润自筹)	✅ 是 (农产品转运商跨界)	✅ 是 (控制炼油瓶颈)
无线电	RCA	❌ 否 (专利池产物)	❌ 否 (轻资产，只收专利费)	❌ 否 (由GE/AT&T等巨头出资)	✅ 是 (巨头合资/政府意志)	✅ 是 (专利授权现金流)
计算机	IBM	❌ 否 (制表机转型)	❌ 否 (早期靠销售服务切入，非研发导向)	❌ 否 (依靠制表机租赁现金流)	✅ 是 (制表机霸主跨界)	✅ 是 (软硬件服务锁定)
互联网	亚马逊/网飞	❌ 否 (应用层公司，非协议发明者)	✅ 是 (必须砸钱建物流/云/服务器)	✅ 是 (依靠VC/发债度过亏损)	✅ 是 (亚马逊卖书积累物流经验，网飞租光盘积累用户信用数据)	✅ 是 (Prime会创内容生)
成功率		22% (2/9) 先发者大多成为先烈	33% (3/9) 大多赢家早期避免重资产投入	11% (1/9) 大多赢家拒绝被资本绑架	88% (8/9) 整合者/跨界者更容易赢	100% (9) 这是唯一

15. Cursor专攻生产力提升的编程工具

公司名称	Anysphere Inc. (产品名为 Cursor)
成立时间	2022 年，由四位 MIT 本科生创立


总部	美国旧金山湾区
创始人团队	Michael Truell（CEO）、Sualeh Asif、Arvid Lunnemark、Aman Sanger（MIT校友，部分辍学创业）
公司愿景	构建未来工程师工具，引领 "后代码时代" 编程范式
大厂孵化情况	无，完全独立创业，拒绝过 OpenAI 收购邀约

时间	关键里程碑
2022年初	团队在 MIT 相识，最初探索 3D 设计工具领域，后转向 AI 编程赛道
2022年中	正式创立 Anysphere，决定辍学专注创业，拒绝大厂 offer
2023年	推出 Cursor 产品（基于 VS Code 深度优化的 AI 原生代码编辑器），采用 "build in public" 策略快速迭代
2023年底	完成种子轮融资 800 万美元，由 OpenAI 创业基金领投
2024年8月	A 轮融资 6000 万美元，a16z 领投，估值 4 亿美元
2024年12月	B 轮融资 1.05 亿美元，Thrive Capital 和 a16z 联合领投，估值 26 亿美元
2025年5月	融资 9 亿美元，估值达 90 亿美元， ARR 突破 5 亿美元
2025年10月	推出自研编程模型 Composer，生成代码量据称超全球多数大模型
2025年11月	D 轮融资 23 亿美元，Accel 和 Coatue 领投，谷歌与英伟达战略投资，估值飙升至 293 亿美元

Cursor 采用 “ToC+ToB 双轨并行，企业端业务快速增长” 的模式：早期以个人开发者为核心用户，2024 年后企业级客户 需求爆发，已成为收入增长主力，服务超60% 财富 500 强企业 ，但仍保留面向个人的订阅产品。

16. AI音乐学园依靠社群起家，后借助AI拓展能力边界及破圈，实现赛道领先
- 基本垄断AI 音乐创作这一偏小众、专业爱好的赛道，且MAU从24年数据监测以来稳健增长并于25年迎来规模爆发
 - 创始人从运营“爱玩吉他”社区起家，早期服务单一乐器品类（吉他、尤克里里）的爱好者和教育者（聚焦青年人），逐步通过融资和AI技术扩展乐器品类和用户年龄范围
 - 由社群起家的AI应用不在少数，虚拟陪伴类的捏TA、逗逗游戏伙伴、蜜小语、Lockey键盘，以及视频创作的闪剪都是锚定明确用户群体起家

启发：由特定爱好发展为社群并成为意见领袖，再运营应用逐渐扩圈、用AI拓展品类逐渐扩大服务范围，进而成为整个小赛道的主流玩家（canva、Lovekey等应用同理）



融资情况

<https://36kr.com/p/1721072091137>
<https://xueqiu.com/8707480199/172203834>

时间	融资轮次	融资数额	投资机构
2015年初	天使轮（爱玩吉他）	400 万元	伙伴创投领投
2019年2月	Pre-A轮融资	数千万	基因资本、港粤资本、京北投资等联合投资
2021年2月	A轮融资	数千万	网易有道（网易有道入股，成为公司第五大股东，持股比例为5.69%）
2021年7月	A轮+融资	数千万	网易云音乐旗下基金

用户增长情况：


2017 年：**AI 音乐学院 APP 上线三个月即实现盈利**，成为国内少数早期实现盈利的在线音乐教育平台

2019 年：付费用户突破 30 万，成为国内最大的吉他 / 尤克里里在线教学平台

2021 年：付费用户超 50 万，累计服务学员超 2000 万

2025 年：累计付费用户达100 万 +，少儿音乐启蒙产品 "音乐壳" 服务 30 万 + 家庭

17. TalkAI



2023年4月：**核心产品上线**：“TalkAI 练口语”正式登陆 iOS 应用商店。这是国内市场上**首个**专注于 AI 原生对话练习的外语学习 App，避开了传统真人外教的高成本模式。

2024年初：**用户突破百万**：受益于 ChatGPT 引发的 AI 浪潮，该应用在社交媒体（小红书、抖音）快速裂变。2024 年 1 月，官方宣布用户数突破 **100 万**。

2024年Q2：**行业爆发与霸榜**：在七麦数据发布的《2024年第一季度 iOS 实力 AI 产品排行榜》中，TalkAI 位列总榜第 15 名，在**语言学习类中排名第 1**

- 2024年实现盈亏平衡

2025年：**B端业务拓展与规模化**：截至 2025 年下半年，TalkAI 官方数据显示其用户量已突破 **1000 万**。产品线从单纯的 C 端订阅延伸至 B 端企业定制，合作客户包括**百度、富士康、华润雪花啤酒**等知名企业。

18. 汇丰报告